langchain 官网位于 <u>python. langchain. com/en/latest/i···</u> ,它可以简化对各种大语言模型的使用,比如内置有 OpenAI 等。

pdfplumber 顾名思义,是用于读取和处理 PDF 文件的,选择这库是因为今年还在更新,并且对中文的支持还不错。本次项目 demo 会导入自己的 PDF 文件,并将其作为知识库,回答你的提问。

python-dotenv 用于读取. env 文件,本例在该文件中放入 Open AI 平台的key。

streamlit 用于绘制 UI 界面,当前大多数 ChatGPT 应用都使用它,如大名鼎鼎的 <u>gpt4free</u>,streamlit 默认会收集信息进行分析,可通过配置文件关闭,macOS 和 Linux 位于[~]/.streamlit/config.toml,Windows 位于%userprofile%/.streamlit/config.toml,添加如下内容即可:

[browser]

gatherUsageStats = false

其它配置项可通过 streamlit config show 可查看。

faiss-cpu 是 facebook 开源用于相似搜索的库, github.com/facebookres…, GPU 版本请使用 faiss-gpu。

openai 和 tiktoken 都是调用 ChatGPT 接口时使用的。

保留当前使用版本请使用 pip freeze > requirements.txt。

OpenAI 的注册方式这里就不介绍了,最常用的是在 <u>sms-activate.org/</u> 上购买服务获取短信验证码完成注册。

提取文本:

接下对文本进行分片,这里每个分片长充为1000字符,为保留上下文选择了重叠200字符:

接下来配置 embedding, 也即将离散值转化为连续向量:

为界面添加一个输入框:

最后完成回复的逻辑: